
Αναγνώριση Προτύπων - Στατιστική Μάθηση

Project 1

Όνομα: Θεοδώρα Αναστασία Λαζαρίδου

AEM: 4673

email: tlazarido@csd.auth.gr

23 Μαρτίου 2026

Περιεχόμενα

Περίληψη	2
Περιγραφή Αλγορίθμων	3
Παραδείγματα ορθής ταξινόμησης	8
Παραδείγματα εσφαλμένης ταξινόμησης	10
Αποτελέσματα αλγορίθμων	13
Πίνακες σύγκρισης	15
Συμπεράσματα	23

Περίληψη

Η παρούσα εργασία εξετάζει την απόδοση των αλγορίθμων k -Πλησιέστερων Γειτόνων (k -NN) και Πλησιέστερου Κέντρου (Nearest Centroid) στο σύνολο δεδομένων MNIST. Μέσα από πειραματικές δοκιμές με διαφορετικές τιμές της υπερπαραμέτρου k και διαφορετικές μετρικές απόστασης (Euclidean, Manhattan), αναλύεται το φαινόμενο της υποεκπαίδευσης (underfitting) και συγκρίνεται η ικανότητα γενίκευσης των δύο μοντέλων.

Περιγραφή αλγορίθμων

- **K-NN classifier - k πλησιέστεροι γείτονες**

Ο αλγόριθμος k πλησιέστεροι γείτονες ($k-NN$) είναι μία μέθοδος, που χρησιμοποιείται τόσο για εργασίες ταξινόμησης όσο και για εργασίες παλινδρόμησης. Ο κύριος σκοπός του είναι να προβλέψει την κλάση ενός νέου σημείου, βρίσκοντας τους k πλησιέστερους γείτονές του στο σύνολο δεδομένων εκπαίδευσης. Στην παρούσα εργασία, θα εστιάσουμε αποκλειστικά στη χρήση του για ταξινόμηση ψηφίων.

Στον αλγόριθμο $k-NN$, το σύνολο δεδομένων εκπαίδευσης αποτελείται από σημεία δεδομένων, όπου κάθε σημείο αντιπροσωπεύεται από ένα σύνολο χαρακτηριστικών και ανήκει σε μία συγκεκριμένη κλάση. Όταν δίνεται ένα νέο σημείο δεδομένων, ο αλγόριθμος αναζητά τους k πλησιέστερους γείτονές του με βάση κάποια μετρική απόστασης, μετρώντας την ομοιότητα ή την ανομοιότητα στον χώρο των χαρακτηριστικών. Δύο από τις πιο συνηθισμένες μετρικές για τα διανύσματα χαρακτηριστικών $x, y \in \mathbb{R}^n$ είναι η Ευκλείδεια απόσταση και η απόσταση Manhattan:

Ευκλείδεια Απόσταση:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Απόσταση Manhattan:

$$d(x, y) = \sum_{i=1}^n |x_i - y_i|$$

Μόλις εντοπιστούν οι k πλησιέστεροι γείτονες, ο αλγόριθμος εκχωρεί την κλάση στο νέο σημείο δεδομένων με βάση την πλειοψηφία των ψήφων των κλάσεων των γειτόνων του.

Η παράμετρος k καθορίζει τον αριθμό των γειτόνων που πρέπει να ληφθούν υπόψη. Είναι μια σημαντική υπερπαράμετρος που πρέπει να επιλεχθεί σωστά για να επιτευχθεί η καλύτερη απόδοση του αλγορίθμου. Από την μία πλευρά, μια μικρή τιμή του k μπορεί να οδηγήσει σε υπερπροσαρμογή (overfitting), όπου ο αλγόριθμος γίνεται ευαίσθητος στον θόρυβο και μπορεί να οδηγήσει σε κακή γενίκευση. Από την άλλη πλευρά, μία μεγάλη τιμή του k μπορεί να οδηγήσει σε υποπροσαρμογή (underfitting), όπου ο αλγόριθμος μπορεί να αποτύχει να συλλάβει τα υποκείμενα μοτίβα στα δεδομένα.

Τα πλεονεκτήματα του αλγορίθμου είναι τα εξής:

1. Είναι απλός και κατανοητός, καθιστώντας τον μία καλή και εύκολη επιλογή.
2. Δεν κάνει υποθέσεις σχετικά με την υποκείμενη κατανομή των δεδομένων, καθιστώντας τον μια μη παραμετρική μέθοδο. Έτσι, έχει την δυνατότητα να χειρίζεται ένα ευρύ φάσμα τύπων δεδομένων και κατανομών.
3. Είναι κατάλληλος τόσο για εργασίες ταξινόμησης όσο και για εργασίες παλινδρόμησης, καθιστώντας τον ευέλικτο στις εφαρμογές του.

Ωστόσο, ο αλγόριθμος αυτός έχει και μερικά μειονεκτήματα:

1. Είναι υπολογιστικά ακριβός κατά την φάση της πρόβλεψης, ειδικά όταν έχουμε να κάνουμε με μεγάλα σύνολα δεδομένων (όπως τα χιλιάδες δείγματα του MNIST). Αυτό συμβαίνει επειδή ο αλγόριθμος πρέπει να υπο-

λογίσει τις αποστάσεις μεταξύ του νέου σημείου δεδομένων και όλων των σημείων δεδομένων εκπαίδευσης.

2. Είναι ευαίσθητος στην επιλογή της μέτρησης της απόστασης. Διαφορετικές μετρήσεις απόστασης μπορεί να αποφέρουν διαφορετικά αποτελέσματα και η επιλογή της μέτρησης εξαρτάται από το συγκεκριμένο πρόβλημα και τα χαρακτηριστικά των δεδομένων.

- **Nearest Centroid classifier - Πλησιέστερα κέντρα**

Ο αλγόριθμος 'Nearest Centroid classifier' είναι αναμφισβήτητα ένας από τους πιο απλούς αλγορίθμους ταξινόμησης στην Μηχανική Μάθηση και λειτουργεί με μια απλή αρχή: δεδομένου ενός άγνωστου σημείου δεδομένων, ο ταξινομητής Κοντινότερου Κέντρου απλώς του αναθέτει την κλάση του δείγματος εκπαίδευσης του οποίου ο μέσος όρος (ή το κέντρο) είναι πιο κοντά σε αυτό. Η διαδικασία που ακολουθεί ο αλγόριθμος αυτός μπορεί να εξηγηθεί σε τρία βήματα:

1. Υπολογίζεται το κέντρο (centroid) μ_c κάθε κλάσης c κατά την εκπαίδευση. Το κέντρο αυτό προκύπτει ως ο μέσος όρος όλων των διανυσμάτων εκπαίδευσης x που ανήκουν στην εν λόγω κλάση C_c :

$$\mu_c = \frac{1}{|C_c|} \sum_{x \in C_c} x$$

2. Μετά την εκπαίδευση, για οποιοδήποτε νέο άγνωστο σημείο x , υπολογίζονται οι αποστάσεις μεταξύ του σημείου x και του κέντρου κάθε κλάσης μ_c , χρησιμοποιώντας την Ευκλείδεια απόσταση:

$$d(x, \mu_c) = \sqrt{\sum_{i=1}^n (x_i - \mu_{c,i})^2}$$

ή την απόσταση Manhattan:

$$d(x, \mu_c) = \sum_{i=1}^n |x_i - \mu_{c,i}|$$

3. Από όλες τις υπολογισμένες αποστάσεις, επιλέγεται η ελάχιστη. Η κλάση $\hat{y}$ του κέντρου στο οποίο η απόσταση από το δοσμένο σημείο είναι η ελάχιστη, ανατίθεται στο δοσμένο σημείο:

$$\hat{y} = \arg \min_c d(x, \mu_c)$$

Όπως κάθε αλγόριθμος, έτσι και αυτός παρουσιάζει συγκεκριμένα πλεονεκτήματα:

1. Είναι εξαιρετικά γρήγορος κατά τη φάση της πρόβλεψης. Σε αντίθεση με τον $k - NN$ που πρέπει να συγκρίνει το νέο δείγμα με ολόκληρο το σύνολο δεδομένων, ο αλγόριθμος του Πλησιέστρου Κέντρου κάνει συγκρίσεις μόνο με τα κέντρα των κλάσεων (στο συγκεκριμένο πρόβλημα, μόνο 10 συγκρίσεις).
2. Απαιτεί ελάχιστη μνήμη, καθώς αποθηκεύει μόνο τα κέντρα των κλάσεων και όχι όλα τα δεδομένα εκπαίδευσης.

Ωστόσο, έχει σημαντικά μειονεκτήματα που περιορίζουν την ακρίβειά του σε σύνθετα προβλήματα:


1. Υποθέτει ότι τα δεδομένα κάθε κλάσης σχηματίζουν μια «σφαιρική» κατανομή γύρω από το κέντρο τους. Αν τα δεδομένα μιας κλάσης (π.χ. διαφορετικοί τρόποι γραφής του ψηφίου '4') έχουν πολύπλοκη ή ασύμμετρη κατανομή, ο μέσος όρος δεν αντιπροσωπεύει σωστά την κλάση.
2. Είναι ευαίσθητος σε ακραίες τιμές, καθώς μια πολύ παραμορφωμένη ει-

κόνα κατά την εκπαίδευση μπορεί να «τραβήξει» το κέντρο μακριά από την ιδανική του θέση.

Παραδείγματα ορθής ταξινόμησης

- K-NN classifier - k πλησιέστεροι γείτονες

Στο Σχήμα 1 παρουσιάζονται έξι τυχαία δείγματα από το σύνολο ελέγχου (test set), τα οποία ο αλγόριθμος k -NN ταξινόμησε επιτυχώς.




Σχήμα 1: Δείγματα ορθής ταξινόμησης για τον αλγόριθμο k -NN με $k = 3$ και Ευκλείδεια απόσταση.

Όπως παρατηρείται, ο αλγόριθμος αναγνωρίζει με μεγάλη ακρίβεια ψηφία που είναι γραμμένα καθαρά και ακολουθούν τις τυπικές μορφές των αριθμών.

Η υψηλή ομοιότητα μεταξύ των διανυσμάτων χαρακτηριστικών των δειγμάτων αυτών και των πλησιέστερων γειτόνων τους στο σύνολο εκπαίδευσης επιτρέπει στον αλγόριθμο να καταλήξει στη σωστή πρόβλεψη.

- **Nearest Centroid classifier - Πλησιέστερα κέντρα**

Στο Σχήμα 2 βλέπουμε παραδείγματα όπου ο αλγόριθμος του Πλησιέστερου Κέντρου πέτυχε τη σωστή πρόβλεψη.




Σχήμα 2: Δείγματα ορθής ταξινόμησης για τον αλγόριθμο Nearest Centroid με Ευκλείδεια απόσταση.

Παρατηρούμε ότι ο αλγόριθμος αυτός, αν και πιο απλός, αποδίδει καλά όταν τα ψηφία είναι «τυπικά». Δηλαδή, όταν η μορφή τους είναι πολύ κοντά στον μέσο όρο (το κέντρο) της κλάσης τους.

Παραδείγματα εσφαλμένης ταξινόμησης

- K-NN classifier - k πλησιέστεροι γείτονες

Παρά το υψηλό ποσοστό επιτυχίας, ο αλγόριθμος υπέπεσε σε ορισμένα σφάλματα ταξινόμησης, τα οποία παρουσιάζονται στο Σχήμα 3.



Σχήμα 3: Δείγματα εσφαλμένης ταξινόμησης για τον αλγόριθμο k-NN με $k = 3$ και Ευκλείδεια απόσταση.


Η ανάλυση των εσφαλμένων δειγμάτων αποκαλύπτει ότι οι αποτυχίες του αλγορίθμου οφείλονται κυρίως σε:

- **Κακογραμμένα ψηφία:** Ορισμένα ψηφία παρουσιάζουν έντονες μουτζούρες ή ελλειπείς γραμμές, με αποτέλεσμα να προσομοιάζουν μορφολογικά με άλλες κλάσεις (π.χ. ένα κακογραμμένο '4' μπορεί να θεωρηθεί '9', όπως φαίνεται στην τρίτη εικόνα της πρώτης γραμμής).
- **Ιδιαίτερη κλίση ή πάχος:** Ψηφία γραμμένα με μεγάλη κλίση ή ασυνήθιστο πάχος γραφής αλλοιώνουν τις αποστάσεις στον πολυδιάστατο χώρο των χαρακτηριστικών (όπως φαίνεται στην πρώτη εικόνα της δεύτερης γραμμής, όπου το μοντέλο πρόβλεψε τον αριθμό '0' ενώ ο πραγματικός ήταν '9').
- **Ασάφεια μεταξύ κλάσεων:** Υπάρχουν περιπτώσεις όπου ακόμα και για το ανθρώπινο μάτι η διάκριση είναι δύσκολη, όπως ανάμεσα στο '1' και το '7' ή στο '3' και το '5'.

- **Nearest Centroid classifier - Πλησιέστερα κέντρα**

Στο Σχήμα 4 παρουσιάζονται έξι δείγματα όπου ο ταξινομητής Πλησιέστερου Κέντρου απέτυχε να προβλέψει τη σωστή κλάση.

Η ανάλυση αυτών των σφαλμάτων επιβεβαιώνει τους περιορισμούς του αλγορίθμου. Σε αντίθεση με τον $k - NN$, ο οποίος εξετάζει τοπικά τα κοντινότερα σημεία, ο Nearest Centroid βασίζεται στον μέσο όρο ολόκληρης της κλάσης. Έτσι, αν ένα ψηφίο είναι κακογραμμένο (π.χ. ένα '7' που μοιάζει με '1'), ο αλγόριθμος το ταξινομεί στην κλάση της οποίας ο μέσος όρος είναι μορφολογικά πιο κοντά σε αυτό το συγκεκριμένο δείγμα.



Σχήμα 4: Δείγματα εσφαλμένης ταξινόμησης για τον αλγόριθμο Nearest Centroid με Ευκλείδεια απόσταση.

Αποτελέσματα Αλγορίθμων

Στην ενότητα αυτή παρουσιάζονται τα ποσοστά ακρίβειας (accuracy) των αλγορίθμων που υλοποιήθηκαν. Η αξιολόγηση έγινε στο σύνολο ελέγχου (test set) το οποίο αποτελείται από 10.000 εικόνες.

Αλγόριθμος	Υπερπαραμέτροι	Ακρίβεια (Accuracy)
k-NN (έτοιμη υλοποίηση)	$k = 3$, Euclidean	97.11%
k-NN (δική μας υλοποίηση)	$k = 3$, Euclidean	97.30%
Nearest Centroid (έτοιμη υλοποίηση)	Euclidean	81.30%
Nearest Centroid (δική μας υλοποίηση)	Euclidean	81.30%

Πίνακας 1: Συγκριτικός πίνακας επιδόσεων των ταξινομητών.

Σχολιασμός Αποτελεσμάτων: Όπως προκύπτει από τον Πίνακα 1, ο αλγόριθμος $k - NN$ υπερτερεί σημαντικά του Nearest Centroid. Αυτό είναι αναμενόμενο, καθώς ο $k - NN$ εξετάζει την τοπική δομή των δεδομένων, ενώ ο Nearest Centroid προσπαθεί να απλοποιήσει κάθε κλάση σε ένα μόνο αντιπροσωπευτικό σημείο (τον μέσο όρο), χάνοντας έτσι πληροφορία για τις ιδιαίτερες μορφές των ψηφίων.

Ιδιαίτερο ενδιαφέρον παρουσιάζει το γεγονός ότι η δική μας υλοποίηση του $k - NN$ σημείωσε ελαφρώς υψηλότερη ακρίβεια (97.30%) έναντι της έτοιμης υλοποίησης της βιβλιοθήκης scikit-learn (97.11%). Η διαφορά αυτή μπορεί να αποδοθεί στον τρόπο διαχείρισης των ισοπαλιών κατά τη διαδικασία της ψηφοφορίας των γειτόνων, όπου

η προσέγγιση που ακολουθήσαμε αποδείχθηκε ελαφρώς πιο αποτελεσματική για το συγκεκριμένο δείγμα του συνόλου δεδομένων MNIST.

Πίνακες σύγκυσης

- ***K* – NN classifier - *k* πλησιέστεροι γείτονες**

1. $k = 3$, Euclidean: 97.30%
2. $k = 100$, Euclidean: 93.77%
3. $k = 2500$, Euclidean: 80.24%
4. $k = 9000$, Euclidean: 65.14%
5. $k = 34500$, Euclidean: 31.95%
6. $k = 60000$, Euclidean: 11.52%
7. $k = 3$, Manhattan: 96.59%
8. $k = 100$, Manhattan: 92.87%
9. $k = 2500$, Manhattan: 76.86%
10. $k = 9000$, Manhattan: 59.18%
11. $k = 34500$, Manhattan: 25.63%
12. $k = 60000$, Manhattan: 11.52%

Αν συγκρίνουμε τα αποτελέσματα των αξιολογήσεων για τις διάφορες τιμές γειτόνων k και τις δύο μετρικές (Ευκλείδεια απόσταση και απόσταση Manhattan) παρατηρούμε δύο σημαντικά φαινόμενα:

-
- **Φαινόμενο Underfitting:** και στις δύο μετρικές που χρησιμοποιήθηκαν, όσο μεγαλώνει το k , η ακρίβεια κατακρημνίζεται.
(στην Ευκλείδεια απόσταση από 97.30% σε 11.52%
στην απόσταση Manhattan από 96.59% σε 11.52%)
 - **Σύγκριση μετρικών:** η Ευκλείδεια απόσταση τα πάει ελαφρώς καλύτερα από την απόσταση Manhattan. Αυτό είναι απολύτως λογικό στο σύνολο δεδομένων MNIST, καθώς η Ευκλείδεια απόσταση αντιλαμβάνεται καλύτερα τις καμπύλες των χειρόγραφων ψηφίων, ενώ η απόσταση Manhattan χάνει λίγη από την οπτική πληροφορία.


Στα Σχήματα 5, 6 παρουσιάζονται οι πίνακες σύγχυσης για τον αλγόριθμο k -NN με χρήση της Ευκλείδειας απόστασης και της απόστασης Manhattan, αντίστοιχα, για τις διάφορες τιμές του k . Ο κάθετος άξονας αντιπροσωπεύει τον πραγματικό αριθμό που απεικόνιζε η εικόνα, ενώ ο οριζόντιος τον αριθμό που προέβλεψε ο αλγόριθμος. Η διαγώνιος είναι οι σωστές προβλέψεις. Όσο πιο σκούρο είναι το χρώμα στη διαγώνιο και όσο μεγαλύτεροι είναι οι αριθμοί εκεί, τόσο πιο καλά τα πήγε το μοντέλο. Εκεί το Predicted label ταυτίζεται με το True label. Τα υπόλοιπα κουτάκια δείχνουν τις λάθος προβλέψεις του αλγορίθμου.

Αναλύοντας τη μορφή των πινάκων, παρατηρούμε ξεκάθαρα την εξέλιξη του φαινομένου της υποεκπαίδευσης (underfitting). Συγκεκριμένα:


- Για $k = 3$ και $k = 100$: Η διαγώνιος είναι έντονα χρωματισμένη, υποδηλώνοντας υψηλή ακρίβεια. Τα σφάλματα εκτός διαγωνίου είναι ελάχιστα, πράγμα που σημαίνει ότι ο αλγόριθμος διακρίνει σωστά τις διαφορές μεταξύ των ψηφίων.
- Για $k = 2500$ και $k = 9000$: Η διαγώνιος αρχίζει να «ξεθωριάζει» και τα σφάλματα αυξάνονται. Επειδή ο αλγόριθμος εξετάζει πλέον υπερ-

βολικά πολλούς γείτονες, χάνει την ικανότητα εντοπισμού των τοπικών, λεπτομερών χαρακτηριστικών του κάθε ψηφίου.

- Για $k = 60000$: Το φαινόμενο της υποεκπαίδευσης φτάνει στο αποκορύφωμά του. Σε αυτή την ακραία περίπτωση, ο αλγόριθμος συμβουλεύεται ολόκληρο το σύνολο εκπαίδευσης (όλες τις 60.000 εικόνες) για κάθε νέα πρόβλεψη. Ως αποτέλεσμα, αγνοεί εντελώς τα χαρακτηριστικά της εισόδου και απλώς επιλέγει συνεχώς την πλειοψηφούσα κλάση του συνόλου, που στο συγκεκριμένο dataset τυχαίνει να είναι το ψηφίο '1'. Αυτό αποτυπώνεται οπτικά με την πλήρη εξαφάνιση της διαγωνίου και τη δημιουργία μιας έντονης, κατακόρυφης στήλης.



Σχήμα 5: Πίνακες σύγχυσης για τον αλγόριθμο k -NN με χρήση Ευκλείδειας απόστασης για $k = 3, 100, 2500, 9000, 34500, 60000$. Παρατηρείται η σταδιακή επιδείνωση των προβλέψεων όσο αυξάνεται το k .



Σχήμα 6: Πίνακες σύγχυσης για τον αλγόριθμο k -NN με χρήση απόστασης Manhattan για $k = 3, 100, 2500, 9000, 34500, 90000$. Παρατηρείται η σταδιακή επιδείνωση των προβλέψεων όσο αυξάνεται το k .

- **Nearest Centroid classifier - Πλησιέστερα κέντρα**

1. Euclidean (το κέντρο είναι ο μέσος όρος): 81.30%
2. Manhattan (το κέντρο θεωρητικά προσεγγίζει τη διάμεσο): 65.76%


Παρατηρώντας τα αποτελέσματα του Nearest Centroid, προκύπτουν τα εξής συμπεράσματα:

- **Υπεροχή Ευκλείδειας απόστασης:** Η Ευκλείδεια απόσταση επιτυγχάνει σημαντικά υψηλότερη ακρίβεια (81.30%) σε σχέση με τη Manhattan (65.76%). Αυτό συμβαίνει διότι ο υπολογισμός του κέντρου ως ο αριθμητικός μέσος όρος των πίξελ (centroid) ελαχιστοποιεί το άθροισμα των τετραγώνων των αποστάσεων (Ευκλείδεια γεωμετρία). Αντίθετα, η απόσταση Manhattan λειτουργεί βέλτιστα όταν το κέντρο ορίζεται από τη διάμεσο (median) των τιμών.
- **Περιορισμοί του μοντέλου:** Η χαμηλότερη απόδοση του Nearest Centroid σε σύγκριση με τον $k - NN$ οφείλεται στο γεγονός ότι ο πρώτος «συμπυκνώνει» όλη την πληροφορία μιας κλάσης σε μία μόνο μέση εικόνα. Στο MNIST, όπου το ίδιο ψηφίο μπορεί να γραφτεί με πολλούς διαφορετικούς τρόπους (π.χ. το 7 με ή χωρίς παύλα), ο μέσος όρος δημιουργεί μια «θολή» αναπαράσταση που δυσκολεύεται να διακρίνει λεπτομέρειες, οδηγώντας σε συχνές συγχύσεις μεταξύ παρόμοιων ψηφίων όπως το 4 και το 9.

Στο Σχήμα 7 παρουσιάζονται οι πίνακες σύγχυσης για τον αλγόριθμο Nearest Centroid με χρήση της Ευκλείδειας απόστασης και της απόστασης Manhattan, αντίστοιχα. Η δομή των πινάκων αυτών είναι ακριβώς η ίδια με την δομή των πινάκων που σχεδιάστηκαν για τον αλγόριθμο $k - NN$.

Αναλύοντας τη μορφή των πινάκων, παρατηρούμε ξεκάθαρα την υπεροχή της Ευκλείδειας απόστασης. Συγκεκριμένα:

-
- **Ευκλείδεια απόσταση:** Παρότι η διαγώνιος διακρίνεται καθαρά, αποκαλύπτονται οι εγγενείς αδυναμίες του αλγορίθμου. Λόγω του ότι το κέντρο προκύπτει από τον μέσο όρο των εικόνων μιας κλάσης, δημιουργούνται «θολά» πρότυπα. Αυτό οδηγεί σε χαρακτηριστικές συγχύσεις μεταξύ ψηφίων που μοιράζονται κοινά γεωμετρικά χαρακτηριστικά, όπως παρατηρείται με το '4' να ταξινομείται συχνά ως '9' (115 φορές) ή το '5' ως '3' (120 φορές).
 - **Απόσταση Manhattan:** Εδώ παρατηρείται μια ισχυρή ανισορροπία στις προβλέψεις, με τον αλγόριθμο να ταξινομεί εσφαλμένα έναν τεράστιο αριθμό δειγμάτων από διάφορες κλάσεις (όπως το '8', το '2' και το '3') στην κλάση '1'. Αυτό το φαινόμενο οφείλεται στην ασυμφωνία μεταξύ του τρόπου υπολογισμού του κέντρου και της μετρικής. Το κέντρο (ως αριθμητικός μέσος) είναι βελτιστοποιημένο για την Ευκλείδεια απόσταση. Όταν χρησιμοποιείται η απόσταση Manhattan, η οποία αθροίζει τις απόλυτες διαφορές των pixels, το ψηφίο '1' ευνοείται λόγω της «αραιότητας» του (έχει τα λιγότερα ενεργά pixels), προσελκύοντας έτσι λανθασμένα πολλά άλλα ψηφία.



Σχήμα 7: Πίνακες σύγχυσης για τον ταξινομητή Nearest Centroid, με χρήση Ευκλείδειας απόστασης και απόστασης Manhattan.

Συμπεράσματα

Συγκρίνοντας τη συνολική απόδοση των δύο αλγορίθμων στο σύνολο δεδομένων MNIST, καθίσταται σαφής η ανωτερότητα του ταξινομητή k -NN έναντι του Nearest Centroid. Ο k -NN (με $k = 3$) άγγιξε ακρίβεια 97.30%, ενώ ο Nearest Centroid περιορίστηκε σε σημαντικά χαμηλότερα επίπεδα (81.30%).

Αυτή η διαφορά οφείλεται στον τρόπο λειτουργίας τους. Ο Nearest Centroid υπολογίζει τον μέσο όρο όλων των δειγμάτων μιας κλάσης, δημιουργώντας ένα μοναδικό «πρότυπο» για κάθε ψηφίο. Αυτή η προσέγγιση είναι υπερβολικά απλοϊκή για χειρόγραφα ψηφία, τα οποία παρουσιάζουν τεράστια ποικιλομορφία στον τρόπο γραφής τους (π.χ. διαφορετικές κλίσεις, πάχος γραμμής, διακόσμηση). Αντίθετα, ο k -NN δεν γενικεύει τα δεδομένα σε ένα κέντρο, αλλά διατηρεί την τοπική πληροφορία του χώρου, επιτρέποντάς του να αναγνωρίζει με επιτυχία πολλαπλά και διαφορετικά στυλ γραφής για το ίδιο ψηφίο, αρκεί να ελεγχθεί το φαινόμενο της υποεκπαίδευσης (underfitting) με την επιλογή ενός κατάλληλα μικρού k .